

Detecção de ASSR em EEG com um Modelo Oculto de Markov

Uma aplicação de processamento de sinais

Victor Ragazzi

Tiago Zanutelli


ELT 610 – Setembro de 2026

Visão geral

1. O problema: encontrar uma resposta auditiva no EEG
2. Do sinal a uma evidência espectral
3. Da evidência a uma sequência de observações
4. Como o HMM acrescenta contexto temporal
5. Treinamento e organização do teste

1. O problema de sinais


- ▶ O EEG tem baixa relação sinal–ruído;
- ▶ a resposta de interesse está em frequências conhecidas;
- ▶ buscamos evidência/observação espectral que também seja persistente no tempo.



2. Usar um HMM?

ORD diz: *“quanta evidência existe nesta janela?”*

O HMM: *“essa evidência forma uma evolução temporal?”*



- ▶ Os estados são ocultos; observamos apenas evidências;
- ▶ O próximo estado depende apenas do estado atual.

3. Organização do EEG

O sinal de cada canal é organizado em **épocas** e analisado por **janelas deslizantes**.



- ▶ Cada janela reúne várias realizações do mesmo experimento;
- ▶ a sobreposição melhora a resolução temporal, mas cria dependência entre janelas vizinhas.


4. Evidência espectral: MSC

Para cada época m , a FFT fornece o coeficiente complexo $X_m(f_0)$ na frequência de interesse f_0 .

Magnitude quadrática da coerência entre épocas


$$\text{MSC}(f_0) = \frac{\left| \sum_{m=1}^M X_m(f_0) \right|^2}{M \sum_{m=1}^M |X_m(f_0)|^2}$$

Fases dispersas



MSC tende a ser menor

Fases alinhadas



MSC tende a ser maior

O teste espectral não é o ponto central

A MSC é uma escolha, não uma restrição do modelo

O HMM precisa de uma sequência de evidências ao longo do tempo, mas essa evidência não precisa vir exclusivamente da MSC.

- ▶ Podemos trocar a MSC por outro teste que seja mais adequado aos dados;
- ▶ também podemos combinar testes complementares, se isso produzir uma evidência mais robusta;


Detector espectral $\longrightarrow$ evidência observada $\longrightarrow$ HMM

5. ORD → Observação

Sob a hipótese de ausência de resposta, a MSC possui uma distribuição nula conhecida para uma janela com M épocas:


$$MSC \mid H_0 \sim \text{Beta}(1, M - 1).$$

O valor de MSC é convertido em um p -valor e depois em um símbolo ordinal:



- ▶ Os cortes vêm de faixas de p -valor da distribuição teórica;
- ▶ o HMM recebe a sequência de labels, não o EEG bruto;
- ▶ frequências laterais são preservadas como controle do detector.

5.1 Como os labels são obtidos





Para cada MSC observada, calculamos a **área de cauda** sob H_0 :

$$p = P_{H_0}(\text{MSC} \geq \text{MSC}_{\text{obs}}).$$

O intervalo que contém esse p -valor determina o label emitido para o HMM. Valores mais à direita são menos prováveis sob H_0 e recebem labels de maior evidência.


5.2 Como construímos exemplos com resposta

A mesma senoide começa com a mesma fase em todas as épocas da janela



5.3 Teste: concatenar diferentes intensidades

Trechos de EEG de diferentes intensidades formam **um único sinal de teste**, por participante, canal e frequência.



Sinal concatenado → **evidências por janela** → **HMM**

Por que concatenar?

O HMM é adequado para identificar **transições entre estados**. Ao variar a intensidade, podemos testar se ele identifica uma possível mudança de ASSR ausente para presente, usando o contexto temporal.

Sinal e intensidades ilustrativos. As janelas ficam dentro de cada trecho; as observações são concatenadas. Uma mudança de intensidade não implica necessariamente uma mudança de estado. Treino e teste usam dados separados.

6. As duas tabelas do modelo

Transição A

Estado atual	Ausente	Presente
Ausente	a_{AA}	a_{AP}
Presente	a_{PA}	a_{PP}

Representa a persistência ou a mudança do estado entre duas janelas.

Emissão B

Estado	muito baixo	baixo	...	alto
Ausente	b_{A1}	b_{A2}	...	b_{AL}
Presente	b_{P1}	b_{P2}	...	b_{PL}

Representa a chance de observar cada nível de MSC em cada estado.

Apenas um exemplo de estrutura

Cada linha de uma matriz probabilística deve somar 1.

7. Como as tabelas são construídas

Matriz de emissão B

- ▶ **Ausente:** histogramas de labels em gravações sem estímulo;
- ▶ **Presente:** os mesmos sinais com uma senoide coerente de pequena amplitude, apenas como cenário sintético;
- ▶ as contagens das frequências são reunidas e normalizadas.

Matriz de transição A


- ▶ Cada gravação contribui com permanências dentro de seu estado;
- ▶ uma saída implícita evita permanência igual a 100%;
- ▶ a tabela expressa duração induzida pelas gravações e pelo janelamento.

Interpretação correta

Esta parametrização é exploratória: não é Baum–Welch, não representa transições fisiológicas observadas e não produz probabilidades clínicas validadas.

7.1 Treinamento: a priori + dados

Os dados atualizam nossa crença sobre um **parâmetro da emissão** do HMM, representado por θ .



Antes: uma crença inicial mais ampla.

Dados: favorecem valores maiores de θ .


Depois: a curva se desloca e fica mais concentrada.

$$p(\theta | D) \propto p(\theta) \times p(D | \theta)$$

Curvas esquemáticas para ilustrar a atualização, sem valores experimentais. A verossimilhança mostra o apoio dos dados a cada valor de θ ; sua altura foi ajustada para comparação visual.


8. Da sequência ao caminho mais provável

Para cada frequência, o algoritmo de Viterbi combina a observação atual com as probabilidades de emissão e transição.



O caminho destacado é somente uma **ilustração**. Participantes e frequências permanecem separados; as intensidades compõem a sequência de teste de cada participante e frequência.

9. Fluxo completo da proposta



- ▶ A FFT isola a componente de interesse;
- ▶ a ORD mede nível de evidência em cada janela;
- ▶ o HMM organiza essa evidência ao longo do tempo.

10. Referências

- ▶ Heintz, Francart e Bertrand (2025) — “Post-processing of EEG-based Auditory Attention Decoding Decisions via Hidden Markov Models”
- ▶ Yao et al. (2026) — “Sample-level EEG-based Selective Auditory Attention Decoding with Markov Switching Models”
- ▶ Antunes, Zanutelli e Felix (2019) — “Automated detection of auditory response: applying sequential detection strategies with constant significance level to magnitude-squared coherence”